한국한의학연구원, 구본초

통계 패키지 활용

***2020*년도 *2*학기 충남대학교 정보통계학과 강의 노트**

Contents

List of Tables

List of Figures

Course Overview

R을 이용한 데이터 분석 시 CRAN에 등록된 패키지를 활용한다. 적절한 패키지의 활용은 데이터 분석의 효율을 증대할 뿐 아니라 분석의 재현성을 향상할 수 있다. 본 강의는 지난학기에 학습한 통계프로그래밍언어 강의 내용의 연속선상에서 진행할 예정이며, 해당 강의에서 학습한 내용들을 기반으로 데이터 분석 및 그 결과에 대한 보고서 작성, 그리고 R 생성 파일에 대한 버전 관리 방법에 대해 알아보고자 한다.

교과 목표

- **R Markdown의 이해와 활용**
- **R 프로그래밍 능력 향상 및 통계 시뮬레이션의 이해**
- **R을 이용한 데이터 분석 실습**
- **R을 이용한 기초 통계분석**
- **텍스트 마이닝에 대한 이해**
- **Shiny, plotly 를 활용한 동적 문서 및 시각화 이해**
- **RStudio + Github을 이용한 버전관리 이해**

선수과목

통계학 개론 통계 프로그래밍 언어

수업 방법

- **강의: 30 %**
- **실험/실습: 70 %**

평가방법

- **중간고사: 35 %**
- **기말고사: 35 %**
- **출석: 10 %**
- **과제: 20 %**

교재

별도의 교재 없이 본 강의 노트로 수업을 진행할 예정이며, 수업의 이해도 향상을 위해 아래 소개할 도서 및 웹 문서 등을 참고할 것을 권장함.

참고문헌

- R Markdown Cookbook[1] (Xie et al., 2020)
- bookdown: Authoring Books and Technical Documents with R Markdown[2] (Xie, 2016)
- R과 knitr를 활용한 데이터 연동형 문서 만들기 (고석범, 2014)
- R for data science[3] (Wickham and Grolemund, 2016)
- Statistical Computing with R (Rizzo, 2019)

[1] https://bookdown.org/yihui/rmarkdown-cookbook/
[2] https://bookdown.org/yihui/bookdown/
[3] https://r4ds.had.co.nz/

- R programming for data science[4] (Peng, 2016)
- Text mining with R[5] (Silge and Robinson, 2017)

[4] https://bookdown.org/rdpeng/rprogdatascience/

[5] https://www.tidytextmining.com/

1

R Markdown

Sketch

- 동일한 문서에 코드, 결과, 텍스트가 동시에 있을 수 있을까?
- 만약 결과와 도표가 자동으로 생성된 경우 데이터가 변경 되더라도 자동으로 문서를 업데이트 할 수 있을까?
- 최종 완료한 문서가 미래에도 열 수 있을까?
- 이러한 모든 과정이 매우 쉽다면??

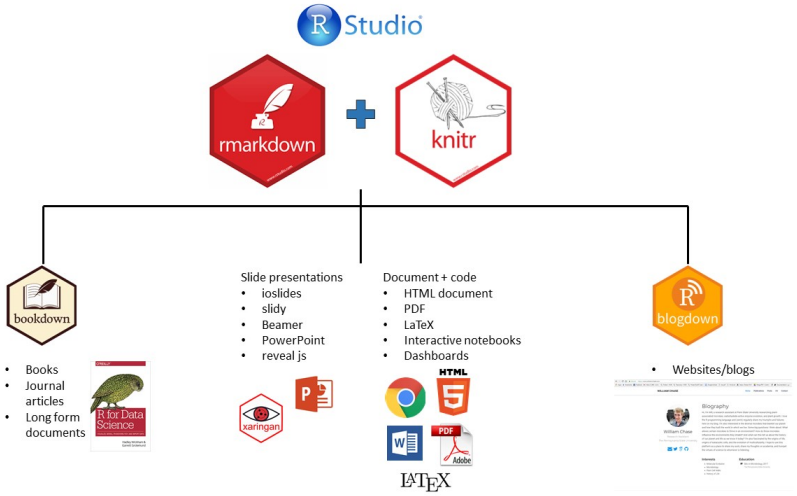

FIGURE 1.1: R markdown 세계 (https://ulyngs.github.io/rmarkdown-workshop-2019 에서 발췌)

1.1 R Markdown의 구성

본 절의 내용 중 일부는 지난 학기 강의노트 1.7절과 중복되거나 재구성한 내용이 포함됨.

1. R Markdown은 R 코드와 분석 결과(표, 그림 등)을 포함한 문서 또는 컨텐츠를 제작하는 도구로 일반적으로 아래 열거한 형태로 활용함
   - 문서 또는 논문(`pdf`, `html`, `docx`)
   - 프리젠테이션(`pdf`, `html`, `pptx`)
   - 웹 또는 블로그
2. 재현가능(reproducible)한 분석 및 연구[1] 가능
   - 신뢰성 있는 문서 작성
   - `Copy & paste`를 하지 않고 효율적 작업 가능

R 마크다운 파일 = `.Rmd` 확장자를 가진 일반 텍스트 파일

````
---
title: "Untitled.Rmd"
date: "2020-09-11"
output: html_document
---


```{r setup, include=FALSE}
knitr::opts_chunk$set(echo = TRUE)
```
````

[1] 과학적 연구의 결과물을 오픈소스로 내놓고 누구라도 검증 가능

```
## R Markdown

Markdown은 HTML, PDF 및 MS Word 문서를 작성하 기위한 간단한 형식 지정 구문입니다.
R Markdown 사용에 대한 자세한 내용은 <http://rmarkdown.rstudio.com>을 참조하십시오.



**Knit** 버튼을 클릭하면 두 가지를 모두 포함하는 문서가 생성됩니다.
문서에 포함 된 R 코드 청크의 출력 내용뿐 아니라
다음과 같이 R 코드 청크를 포함 할 수 있습니다.

```{r cars}
summary(cars)
```

Including Plots

You can also embed plots, for example:

```{r pressure, echo=FALSE}
plot(pressure)
```

`echo = FALSE` 매개 변수가 코드 청크에 추가되었습니다.
플롯을 생성 한 R 코드의 인쇄를 방지합니다.
```

위 R Markdown 문서는 아래 그림과 같이 **YAML**, **Markdown 텍스트**, **Code Chunk** 세 부분으로 구성됨.

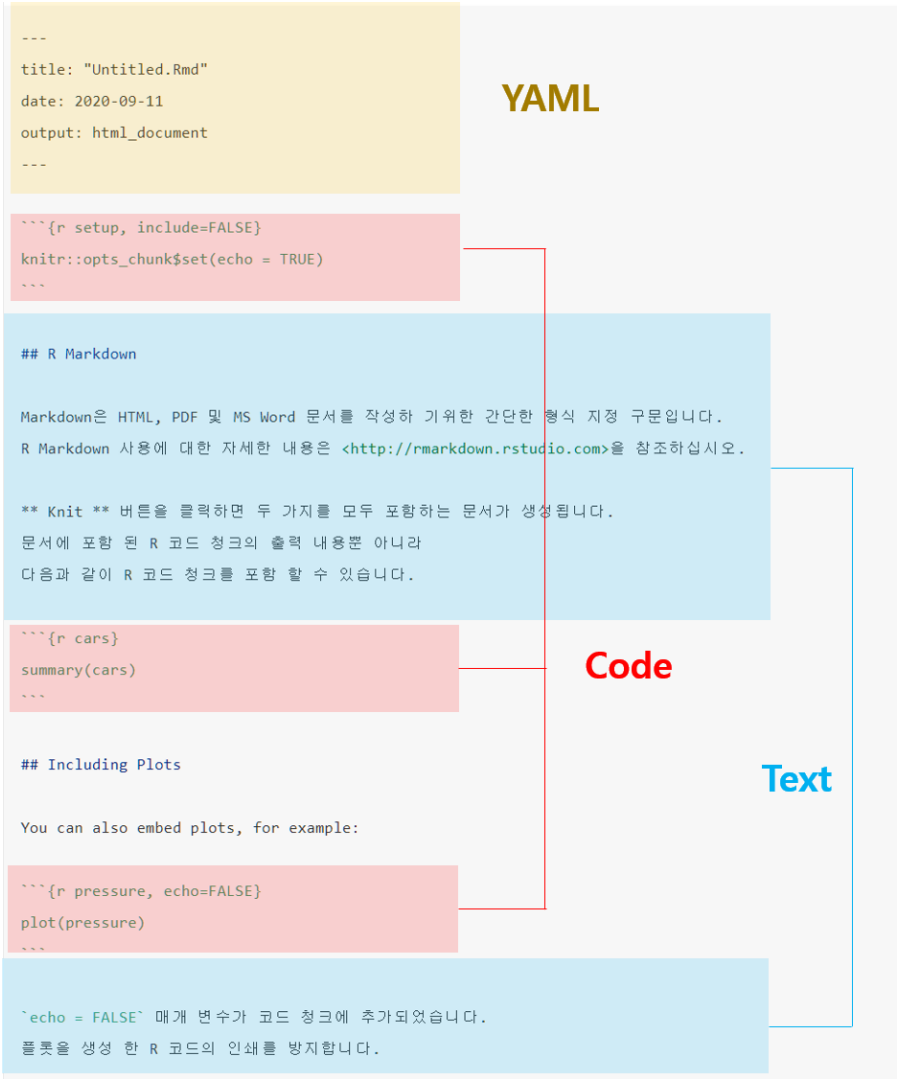

FIGURE 1.2: R markdown structure

YAML (YAML Ain't Markup Language)

- R Markdown 문서의 metadata로 문서의 맨 처음에 항상 포함(header) 되어야 함.
- R Markdown 문서의 최종 출력 형태(`html`, `pdf`, `docx`, `pptx` 등), 제목, 저자, 날짜 등의 정보 등을 포함

최종 문서 생성 과정

- `Rmd` 파일을 `knitr` 을 통해 `.md` 파일로 변환 후 `pandoc` 이라는 문서 변환기를 통해 원하는 문서 포맷으로 출력

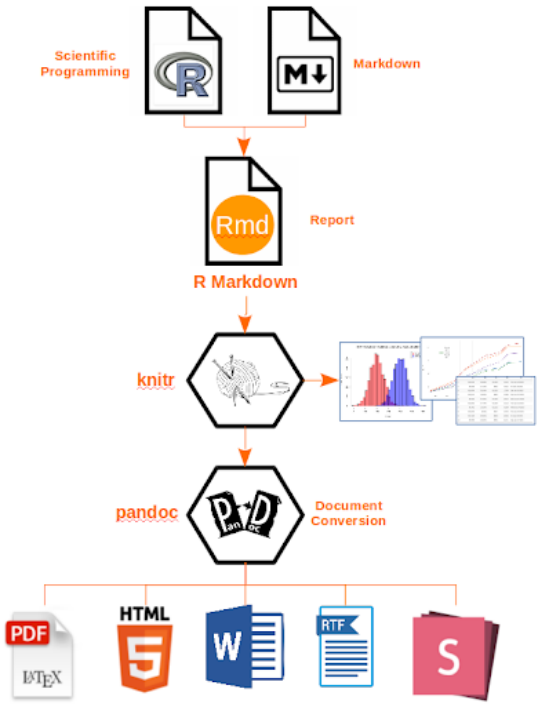

FIGURE 1.3: R Markdown의 최종 결과물 산출과정 (http://applied-r.com/project-reporting-template/)

1.2 R Markdown 문서 시작하기

- **R Markdown** 문서 생성: `[File] -> [New File] -> [R Markdown..]`을 선택

RStudio를 처음 설치하고 위와 같이 진행할 경우 아래와 같은 패키지 설치 여부를 묻는 팝업 창이 나타남. 패키지 설치 여부에 `[Yes]`를 클릭하면 R Markdown 문서 생성을 위해 필요한 패키지들이 자동으로 설치

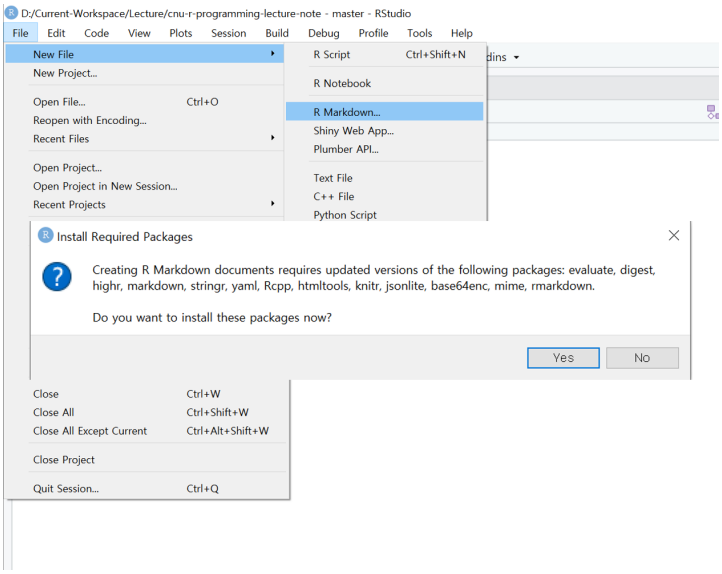

- 설치 완료 후 R Markdown으로 생성할 최종 문서 유형 선택 질의 창이 나타남. 아래 창에서 제목(Title)과 저자(Author) 이름 입력 후 `[OK]` 버튼 클릭 (`Document`, `html` 문서 선택)

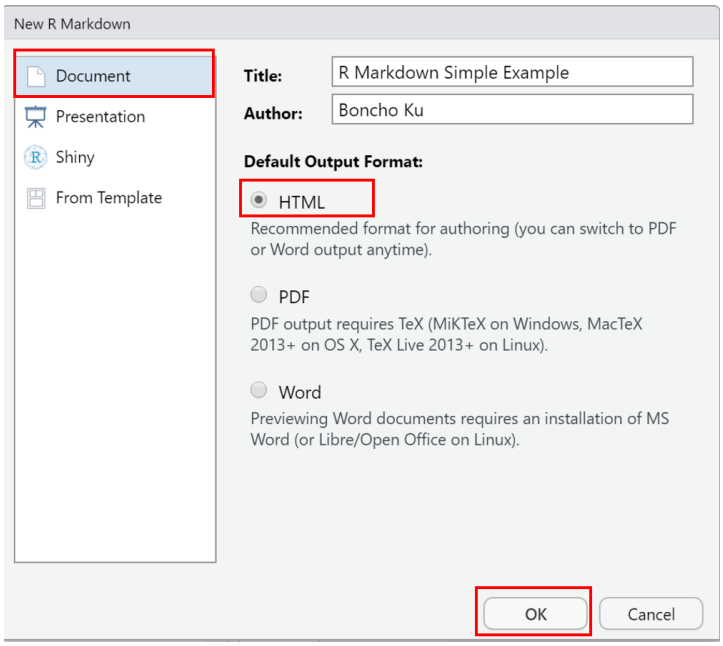

- 아래 그림과 같이 새로운 문서 창이 생성되고 `test.Rmd` 파일로 저장[2]

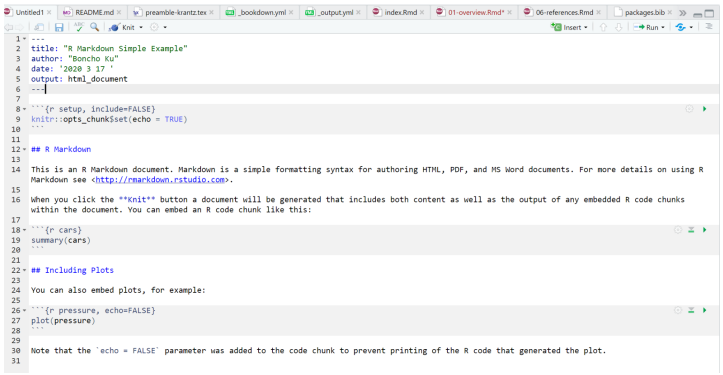

- 문서 상단에 `Knit` 아이콘을 클릭 후 `Knit to HTML` 클릭 또는 문서 아무 곳에 커서를 위치하고 단축키 `[Ctrl] + [Shift] + [K]` 입력

[2] [RStudio 프로젝트]에서 생성한 폴더 내에 파일 저장

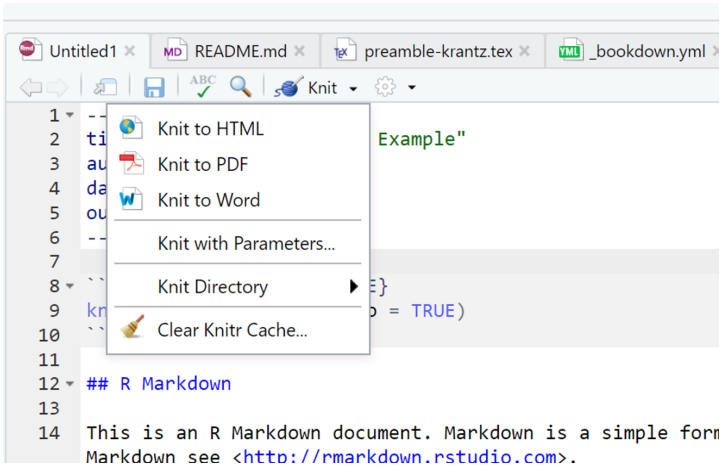

- `knitr` + `R Markdown` + `pandoc` → `html` 파일 생성 결과

FIGURE 1.4: test.html 문서 화면(저장 폴더 내 'test.html'을 크롬 브라우저로 실행)

1.3 R Markdown 기본 문법 (syntax)

R Markdown의 기본 문법은 Rstudio 풀다운 메뉴 **[Help]** → **[Markdown Quick Reference]** 에서 확인 가능

1.3.1 텍스트 문법

강조 (emphasis)

- 이텔릭체 : *italic1*, _italic2_ → *italic1*, *italic2*
- 볼드 (굵은) 체 : ***bold1***, ___bold2___ → **bold1**, **bold2**

Inline code

- ‘inline code‘ → `inline code`

아래/위 첨자 (sub/superscript)

- subscript~2~ → subscript$_2$
- superscript^2^ → superscript^2

삭제표시 (strike through)

- ~~strikethrough~~ → ~~strikethrough~~

생략표시 (ellipsis)

- ... → …

긴/짧은 대쉬 (en/emd-dash)

- 짧은 대쉬 : -- → –
- 긴 대쉬 : --- → —

특수문자 탈출 지정자

- *, _, \~, \\ → *, _, ~, \

하이퍼링크

-`[text](link)` → 통계프로그래밍언어[3]

외부그림 삽입

- `![image title](path/to/image)`: ![장난꾸러기](figures/son-02.jpg)

강제 줄바꿈(line breaks)

- 하나의 줄에서 공백(space) 두 개 이상 또는 백슬레시(\) 입력 후 [Enter]

```
End a line with two spaces to start
a new paragraph
```

End a line with two spaces to start a new paragraph

```
End a line with two spaces to start\
a new paragraph
```

End a line with two spaces to start
a new paragraph

각주(footnote)

- `A footnote^[주석내용]` → A footnote[4]

[3] https://zorba78.github.io/cnu-r-programming-lecture-note
[4] 주석내용

FIGURE 1.5: 장난꾸러기

주석 (comment)

- `<!-- this is a comment that won't be shown -->` →

RStudio에서 단축키 `[Ctrl]` + `[Shift]` + `[C]`를 통해 전체 line 에 대해 주석처리 가능

1.3.2 Block-level elements

장/절(header)

- # Header 1 (chapter, 장)
- ## Header 2 (section, 절)
- ### Header 3 (subsection, 관)

목록(list)

- 비순서(unordered) 목록: `-`, `*`, `+` 중 어느 하나로 입력 가능

```
- one item
* two item
   + sub-item 1
   + sub-item 2
      - subsub-item 1
      - subsub-item 2
```

- one item
- two item
  - sub-item 1
  - sub-item 2
    - subsub-item 1
    - subsub-item 2
- 순서(ordered) 목록: 비순서 목록의 기호 대신 숫자로 리스트 생성

```
1. the first item
   - sub-item 1
```

```
2. the second item
3. the third item
```

1. the first item
    - sub-item 1
2. the second item
3. the third item

- 같은 숫자로 적어도 순서대로 목록 생성

```
1. the first item
   - sub-item 1
1. the second item
1. the third item
```

1. the first item
    - sub-item 1
2. the second item
3. the third item

인용구(blockquote): >로 시작

```
> "There are three kinds of lies: lies, damn lies, and statistics"
>
> --- Benjamin Disraeli
```

> "There are three kinds of lies: lies, damn lies, and statistics"

— Benjamin Disraeli

1.3.3 수식표현(math expression)

- 줄 안에 수식 입력 시 `$수식표현$` 으로 입력
- 수식 display style (보통 교과서에 정리 및 정의에 기술된 수식들) 적용 시 `$$ ~ $$` 안에 수식 입력
- 수식 표현은 LaTeX 의 수식 표현을 동일하게 준용(https://www.latex4technics.com/, https://latex.codecogs.com/legacy/eqneditor/editor.php 에서 수식 입력 명령어 학습 가능)
- LaTeX 수식 입력 코드는
- 예시

$$P(X = x) = f(x; n, p) = \binom{n}{x} p^x (1-p)^{n-x}$$

- Inline equation: `$P(X = x) = f(x; n, p) = {n \choose x} p^x (1-p)^{n-x}$` → $P(X = x) = f(x; n, p) = \binom{n}{x} p^x (1-p)^{n-x}$
- Math block: `$$P(X = x) = f(x; n, p) = {n \choose x} p^x (1-p)^{n-x}$$`

$$P(X = x) = f(x; n, p) = \binom{n}{x} p^x (1-p)^{n-x}$$

- `$ $` 또는 `$$ $$` 안에 LaTeX에서 제공하는 수식 함수 사용 가능

```
$$\begin{array}{ccc}
x_{11} & x_{12} & x_{13}\\
```

```
x_{21} & x_{22} & x_{23}
\end{array}$$
```

$$
\begin{array}{ccc}
x_{11} & x_{12} & x_{13} \\
x_{21} & x_{22} & x_{23}
\end{array}
$$

```
$$\Theta = \begin{pmatrix}\alpha & \beta\\
\gamma & \delta
\end{pmatrix}$$
```

$$
\Theta = \begin{pmatrix}\alpha & \beta \\ \gamma & \delta \end{pmatrix}
$$

```
$$\begin{align}
g(X_{n}) &= g(\theta)+g'({\tilde{\theta}})(X_{n}-\theta) \notag \\
\sqrt{n}[g(X_{n})-g(\theta)] &= g'\left({\tilde{\theta}}\right)
  \sqrt{n}[X_{n}-\theta ]
\end{align}$$
```

$$
\begin{aligned}
g(X_n) &= g(\theta) + g'(\tilde{\theta})(X_n - \theta) \\
\sqrt{n}[g(X_n) - g(\theta)] &= g'\left(\tilde{\theta}\right)\sqrt{n}[X_n - \theta]
\end{aligned}
$$

1.4 R Code Chunks

- 실제 R code가 실행되는 부분임

- Code chunk 실행 시 다양한 옵션 존재(본 강의에서는 몇 개의 옵션만 다룰 것이며, 더 자세한 내용은 https://yihui.org/knitr/options/ 또는 R Markdown 레퍼런스 가이드[5] 참조
- Code chunk는 ```{r}로 시작되며 r은 code 언어 이름을 나타냄.
- Code chunk는 ``` 로 종료
- R Markdown 문서 작성 시 단축키 [Ctrl] + [Alt] + [I]를 입력하면 Chunk 입력창이 자동 생성됨
- Code chunk의 옵션 조정을 통해 코드의 출력여부, 코드 출력 시 코드의 출력 형태, 코드의 결과물 출력 조정 가능

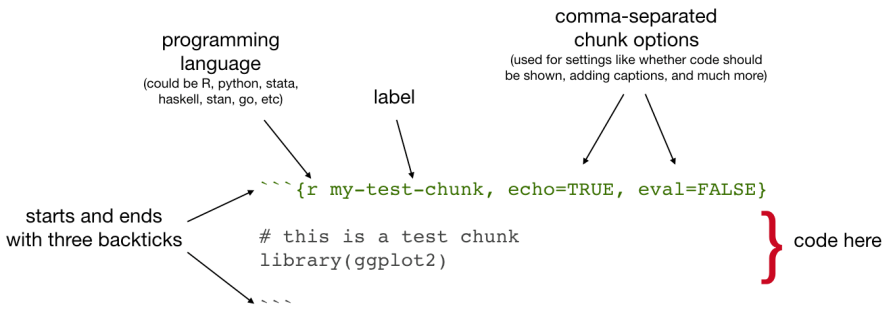

FIGURE 1.6: Chunk anatomy (https://ulyngs.github.io/rmarkdown-workshop-2019 에서 발췌)

자주 활용하는 chunk 옵션

- 코드 실행 관련 청크

[5] https://rstudio.com/wp-content/uploads/2015/03/rmarkdown-reference.pdf

TABLE 1.1: 코드 실행 관련 청크

Chunk 옵션	Default	설명
eval	TRUE	R 실행 결과에 대응하는 코드 출력 여부
include	TRUE	출력 문서에 코드 청크의 내용을 포함할지 여부

````
```{r ex01-1, eval=TRUE}
summary(iris)
hist(iris$Sepal.Length)
```


```{r ex01-2, eval=FALSE}
summary(iris)
hist(iris$Sepal.Length)
```
````

```
#청크 옵션 eval=TRUE
summary(iris)
```

```
  Sepal.Length    Sepal.Width     Petal.Length    Petal.Width
 Min.   :4.300   Min.   :2.000   Min.   :1.000   Min.   :0.100
 1st Qu.:5.100   1st Qu.:2.800   1st Qu.:1.600   1st Qu.:0.300
 Median :5.800   Median :3.000   Median :4.350   Median :1.300
 Mean   :5.843   Mean   :3.057   Mean   :3.758   Mean   :1.199
 3rd Qu.:6.400   3rd Qu.:3.300   3rd Qu.:5.100   3rd Qu.:1.800
 Max.   :7.900   Max.   :4.400   Max.   :6.900   Max.   :2.500
       Species
 setosa    :50
 versicolor:50
```

```
 virginica :50
```

```
hist(iris$Sepal.Length)
```


```
#청크 옵션 eval=FALSE
summary(iris)
hist(iris$Sepal.Length)
```

-

- echo: R 실행 결과에 대응하는 코드 출력 여부 (TRUE/FALSE, default = TRUE)

- eval: chunk 안에 작성한 스크립트(코드)의 실행 여부(TRUE/FALSE, default = TRUE)

- `include`: chunk 출력물을 출력 문서에 포함할지 여부 결정(`TRUE/FALSE`, `default = TRUE`)
- `results`:
- `error`:
- `message`:
- `warning`:
- `fig.cap`:
- `dpi`: 출력

Bibliography

Peng, R. D. (2016). *R programming for data science*. Learnpub.

Rizzo, M. L. (2019). *Statistical computing with R*. CRC Press.

Silge, J. and Robinson, D. (2017). *Text mining with R*. " O'Reilly Media, Inc.".

Wickham, H. and Grolemund, G. (2016). *R for data science: import, tidy, transform, visualize, and model data*. " O'Reilly Media, Inc.".

Xie, Y. (2016). *bookdown: Authoring Books and Technical Documents with R Markdown*. Chapman and Hall/CRC, Boca Raton, Florida. ISBN 978-1138700109.

Xie, Y., Dervieux, C., and Riederer, E. (2020). *R Markdown Cookbook*. Chapman and Hall/CRC, Boca Raton, Florida. ISBN 978-1000290806.

고석범 (2014). *R*과 *knitr*를 활용한 데이터 연동형 문서 만들기. 에이콘 출판사, 1st edition. ISBN 978-8960775510.